

자동화 기반 병합 알고리즘을 활용한 문서 관리 애플리케이션*

김재영, 서예은, 김진호, 문이빈, 안동혁^o

창원대학교

gkgkgkth12@gs.cwnu.ac.kr, 20223114@gs.cwnu.ac.kr, 20173051@gs.cwnu.ac.kr, muniebin@gmail.com,

Donghyeokan@changwon.ac.kr

Document Management Application Using Automation-Based Integrated Algorithm

Jaeyoung Kim, Yeaeun Seo, Jinho Kim, Iebin Moon, Donghyeok An^o

Dept. of Computer Engineering, Changwon National University

요약

업무 관리 방식의 패러다임이 변화함에 따라 현업에서는 주로 디지털 기반 문서를 활용한다. 그러나 문서의 병합 및 관리 업무는 수작업으로 수행되고 있는 실정이며, 이는 효율성 및 정확성 측면에서 일관성이 보장된 결과를 기대하기 어렵다. 본 논문에서 제안하는 애플리케이션은 자동화 기반 병합 알고리즘을 활용하여 기존 프로세스의 한계점을 극복하고 효과적인 문서 병합을 제공한다.

1. 서론

디지털화는 조직의 데이터를 고급 디지털 기술로 처리하는 과정을 의미하며, 조직 내 구축된 시스템 및 플랫폼을 기반으로 하여 데이터를 보다 효율적이고 체계적인 관리가 가능하게 한다. 이에 따라, 현대 사회에서의 다양한 분야에서 디지털화 및 해당 과정에 따른 시스템 및 플랫폼 구축의 중요성이 더욱 두드러지고 있다. [1]의 연구는 설계 분야에서 실제 제품이 제조되기 전 2D 도면 및 3D 모델을 설계 및 생성하는 CAD(Computer-Aided Design) 프로그램과 제품 미래 성능을 예측하고 평가하는 CAE(Computer-Aided Engineering) 프로그램과 같이, 유사한 목적을 가진 이종 시스템 간의 통합을 지원하기 위한 플랫폼을 구축하였다. 또한, [2]의 연구는 임상 실험 의뢰 분야에서 사용되는 데이터의 형태가 아날로그 기반에서 디지털 기반 형태로 변화함에 따라, 다양한 기관에서 사용하는 서로 다른 프로그램 간의 데이터 및 워크플로우 통합을 지원하기 위한 통합 모듈을 개발하였다. 문서 병합 및 관리 분야에서는 Adobe Acrobat[3], MS Word[4], MS Excel[5]과 같은 특정 문서 프로그램에 내부적으로 구현된 자체적 기능을 활용하는 방안과 외부적으로 구현된 Aspose[6]와 같은 서드 파티 프로그램을 활용하는 방안이 존재한다. 하지만, 해당 방안들은 [표 1]과 같은 특징을 기반으로 4가지 측면에서의 한계점이 존재한다. 먼저 정교성 측면에서,

Adobe Acrobat 기반 '.pdf' 파일 형식 문서 병합은 높은 정교성을 보이는 반면, 타 프로그램은 병합 문서가 원본 문서들의 서로 다른 글꼴 및 스타일을 유지하지 못하거나 테이블이 페이지 영역을 침범하는 등과 같은 문제가 존재한다. 확장성 측면에서, MS Word 및 MS Excel 기반 '.docx', '.xlsx' 파일 형식 문서 병합의 경우 각각 동종 형식 문서들에 한정하여 병합이 가능한 한계점이 있다. 또한, Adobe Acrobat의 경우 서로 다른 이종 형식 문서 병합이 가능하지만, 사전 수작업을 통해 문서를 '.pdf' 파일 형식으로 변환 후 병합해야 하는 번거로움이 존재한다. 기능성 측면에서, 특정 페이지 선택 및 특정 자료형 선택과 같이 병합 과정에서 부가적으로 지원하는 특정 기능이 부족한 한계점이 존재한다. 마지막 보안성 측면에서, 기관 및 기업에서 대외비 문서를 사용하여 문서 병합을 진행할 경우, 서드파티 프로그램을 사용하는 것은 보안에 취약할 수 있으며, 추가 비용을 지불해야 한다는 점 또한 단점으로 존재한다.

	Adobe Acrobat	MS Word	MS Excel	Aspose
정교성	높음	보통	보통	보통
확장성	높음	보통	보통	높음
기능성	보통	낮음	낮음	높음
보안성	높음	높음	높음	낮음

[표 1] 관련 프로그램

추가적으로, 현재 대다수의 기업들은 대량의 문서 병합 과정을 수작업으로 진행하고 있다. 이에 따라 전체 문서 내용에 대한 깊은 이해도와 관리 능력이 있는 관리자가 필수적이며, 문서 병합 과정에서 휴먼 오류의 발생 가능성과 인적 자원에 대한 의존성

* 본 과제(결과물)는 교육부와 한국연구재단의 재원으로 지원을 받아 수행된 3단계 산학협력 선도대학 육성사업(LINC 3.0)의 연구 결과입니다. 이 논문은 2024년도 정부(산업통상자원부)의 재원으로 한국산업기술진흥원의 지원을 받아 수행된 연구입니다. (P0017006, 2024년 산업혁신인재성장지원사업)


이 존재한다. 본 논문에서는 앞서 기술된 4가지 측면에서의 개발 방향성 관점을 고려하여, 널리 사용되는 MS Word 및 MS Excel 문서 형식에 초점을 맞춰 불필요한 인력 및 비효율적인 업무 프로세스를 제거를 위한 자동화 기반 문서 병합 알고리즘 설계 후 해당 알고리즘을 기반으로 한 애플리케이션을 개발하는 것을 목적으로 한다.

본 논문의 구성은 다음과 같다. 2장에서 문서 구조 및 문서 병합 알고리즘 및 애플리케이션에서 지원하는 기능들을 기술하며, 3장에서는 병합 결과에 대한 내용을 기술한다. 마지막으로, 4장에서 향후 연구 및 결론을 기술한다.

2. 본 론

2.1. 문서 구조

OOXML(Office Open XML)[7]은 XML 기반의 개방형 표준으로, 문서의 내용과 구조가 체계적으로 정의되어 있다. MS Word의 대표적인 ‘.docx’ 파일 형식과 MS Excel의 ‘.xlsx’ 파일 형식은 OOXML 표준에 맞춰 구조화되어 있다. OOXML 문서는 ‘.zip’ 파일 형식으로, OPC(Open Packaging Conventions) 규격에 따라 [그림 1]과 같이 문서 내용과 관련 데이터들이 분리된 XML 파일과 폴더로 구성된다. 워드 문서의 경우 WordprocessingML 규격에 따라 텍스트, 이미지, 테이블, 스타일 등이 XML 태그로 표현되며, 엑셀 문서의 경우 SpreadsheetML 규격에 따라 워크시트 데이터, 병합된 셀 정보, 스타일 등이 XML 태그로 표현된다.



[그림 1] OOXML 문서 구조


2.2. 문서 병합 알고리즘

OOXML 문서의 구조를 기반으로 한 MS Word 및 MS Excel 문서 병합 알고리즘은 각각 [그림 2]의 (a), (b)와 같다. 먼저 MS Word의 경우, 이미지 참조 업데이트 과정에서 병합된 문서에서 사용되는 이미지를 원본 문서에서 추출하여 해당 이미지에 대한

참조 ID를 업데이트한다. 넘버링 고유 ID 할당 단계에서는 목차와 같은 요소에 고유한 ID를 할당하며, 목차나 다른 숫자로 표현된 구성 요소의 번호를 분석하여 충돌을 방지하고 병합된 문서에서 올바른 순서를 유지할 수 있도록 조정한다. 스타일 처리 단계에서는 원본 문서에서 사용하던 사용자 지정 스타일 등을 병합된 문서에서 사용할 수 있도록 처리한다.

요소 추가 단계에서는 원본 문서에 존재하는 요소들을 순서대로 병합된 문서에 추가한다.

다음으로 MS Excel의 경우, 테이블 연관성 판단 단계에서는 병합된 문서 내의 테이블과 원본 문서 내의 테이블 간에 동일한 열을 포함하고 있는지 판단한다. 판단 결과에 따라 연관성이 존재할 경우, 동일한 열을 기준으로 서로 다른 테이블들을 병합하여 새로운 단일 테이블을 생성하는 추가적인 과정을 수행한다. 이후 요소 추가 과정을 수행하며, 스타일 처리 단계에서는 셀의 병합 구조 및 글씨체와 같은 스타일을 처리한다.



[그림 2] 문서 병합 과정

2.3. 구현 기능

문서 병합 알고리즘을 기반으로 구현된 문서 병합 애플리케이션의 기능들은 다음과 같다. 첫 번째로, 텍스트, 이미지, 테이블 등을 포함한 다양한 자료형을 갖춘 문서들에 대해 정교한 병합이 가능하다. 두 번째로, 사용자가 원본 문서들의 특정 페이지를 선택하여 필요한 부분만 병합할 수 있게 한다. 세 번째로, 특정 자료형을 선택하여 병합하는 기능을 제공한다. 이는 사용자가 병합 문서를 시각화 자료 및 요약 문서로 활용하기 위해 이미지나 테이블만을 병합하고자 할 때 유용하다. 네 번째로, 병합된 단일 엑셀 파일에 대해 서로 동일하거나 상이한 워크시트로 병합하는 기능을 제공한다. 먼저 동일한 워크시트로 병합하는 경우, 열 또는 행 방향을 특정하여 테이블이 추가되는 방향을 선택할 수 있다. 이는 여러 워크시트를 하나의 워크시트에 통합하여 관리할 수 있게 한다. 반면 상이한 워크시트로 병합하는 경우,

(a) 원본 문서1

(b) 원본 문서2

·업단 3차년도 참여할

(c) Aspose 기반 병합 문서

LINC 3.0 사업단 3차년도 참여학사조직 현황

(d) 자체 애플리케이션 기반 병합 문서

[그림 3] 동일한 워크시트 병합 결과

(a) 원본 문서

(b) 병합 문서

[그림 4] 특정 자료형 병합 결과

이를 기반으로 주작업을 통해 중복을 제거하는 불필요한 과정을 줄이는 동시에, 특정 테이블 기준으로 스타일 선택이 가능함으로써 효율적인 병합을 지원한다는 특징이 있다.

본 논문에서 제안하는 애플리케이션의 성능을 평가하기 위해 기존 문서 병합 프로그램 기반 병합 결과와 비교하였다. **[그림 3]**의 (a), (b)는 각각 원본 MS Excel 파일이며 (c), (d)는 각각 Aspose와 자체 개발 애플리케이션을 이용한 병합 결과를 보여 준다. Aspose 기반 문서 병합 결과는 원본의 스타일을 제대로 유지하지 못하는 문제가 있는 반면, 자체 개발 애플리케이션은 자연스러운 레이아웃을 제공함을 확인할 수 있다. 또한, 제안하는 애플리케이션은 **[그림 4]**와 같이 사용자가 원하는 특정 페이지 또는 특정 자료형을 선택하여 병합이 가능한 추가 기능을 제공한다.

본 연구에서는 자동화 기반 문서 병합 알고리즘을 설계하고 문서 병합 애플리케이션을 개발함으로써 문서 병합 및 관리의 효율성을 높이는 방안을 제시하였다.

향후 확장성을 고려한 메타 데이터 기반 통합 스키마의 구성을 통해 이중 형식 문서 병합을 지원할 수 있는 애플리케이션 및 입출력 문서를 체계적으로 관리할 수 있는 통합 문서 관리 시스템 및 플랫폼을 구축하는 것을 목표로 하고 있다.

[1] Md Tarique Hasan Khan, Saki Rezwana, A review of CAD to CAE integration with a hierarchical data format(HDF)-based solution, Journal of King Saud University, Vol 33, Issue 4, pp. 248-258, 2021.

[2] Haak, D., Samsel, C., Gehlen, J. et al. Simplifying Electronic Data Capture in Clinical Trials: Workflow Embedded Image and Bio-signal File Integration and Analysis via Web Services. J Digit Imaging. Vol 27, pp. 571-580, 2014.

[3] Adobe Acrobat, <https://www.adobe.com>

[4] MS Word, <https://www.microsoft.com/word>

[5] MS Excel, <https://www.microsoft.com/excel>

[6] Aspose, <https://www.aspose.com>

[7] OOXML, <https://www.officeopenxml.com>